

Потоки и процессы. Celery. MapReduce

@pvavilin

11 марта 2023 г.

Outline

Процесс

Это программа, находящаяся в режиме выполнения. Операционная система подгружает в оперативную память с каждым процессом

- Саму программу
- Данные к программе
- Стек программы

Переключение между процессами происходит на уровне ядра.

Поток

- Каждый процесс состоит из минимум одного потока.
- Потоки разделяют общее адресное пространство процесса.

Переключение между потоками может происходить как на уровне ядра, так и на уровне пользователя (процесса).

Что можно узнать про процесс?

```
ps alx  
ls -l /proc/<PID>/
```

создание процессов

Для создания нового процесса используются системные вызовы копирования процесса:

`fork` UNIX-системы

`CreateProcess` Win2k-системы

CPU-bound / IO-bound задачи

CPU-bound задачи, которые активно используют CPU.
Арифметические операции, матричные
вычисления, поиск строк, и т.д.

IO-bound задачи, связанные с вводом-выводом данных.
Работа с сетью, с файловыми системами, с
пользовательским вводом

GIL


Python/ceval.c

```
/* This is the GIL */  
static PyThread_type_lock  
    interpreter_lock = 0;
```


GIL

GIL гарантирует интерпретатору, что только один *поток* может быть запущен в текущий момент. Это сделано для безопасной работы управления памятью, вызова расширений написанных на других языках (на C).

GIL



- `sys.getcheckinterval()` # -> Python2
- `sys.getswitchinterval()` # -> Python3

GIL

GIL замедляет CPU-bound задачи. Старая реализация GIL очень плохо работала с *CPU-bound + IO-bound* задачами. Пример, да и новая не лучше.

Практика

GitHub

Дополнительная литература

- GIL
- UnderstandingGIL.pdf
- Groking The GIL
- GIL и его влияние на многопоточность в Python
- multiprocessing

Что такое Celery?

Официальная документация

Celery это брокер задач, который позволяет в фоновом, асинхронном режиме выполнять задачи в отдельных процессах/тредах и/или на других машинах.

Практика запуска задач на Celery

```
pip install celery  
apt install rabbitmq-server
```

- Можно описывать сложные последовательности

Что такое map-reduce

Это процесс решения больших задач при помощи разбивки данных на части и решения задач с частями данных на разных машинах. MapReduce состоит из обязательных шагов:

- 1 Map — разбить данные на блоки (присвоить каждой записи некоторый ключ блока)
- 2 Shuffle — присвоить каждому блоку некоторый ключ (*не-уникальный* между всеми блоками)
- 3 Reduce — для каждого ключа выполнить некоторую функцию над всеми данными в этом ключе

Практика запуска map-reduce на pyspark

тестовая сборка для работы с Hadoop (надо дополнительно поставить python на namenode)

- mapper.py
- reducer.py

Практика запуска map-reduce на pyspark

■ запуск на NameNode

```
hdfs dfs -rm -r -skipTrash\  
/d/out  
hadoop jar /opt/hadoop-2.7.4/share\  
/hadoop/tools/lib/  
hadoop-streaming-2.7.4.jar\  
-files /root/mapper.py,\  
/root/reducer.py\  
-mapper /root/mapper.py\  
-reducer /root/reducer.py\  
-input /d/in/98.txt\  
-output /d/out  
hdfs dfs -cat /d/out/part-00000
```

Вопросы-ответы

